



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO I

ESBOÇO DE STORYTELLING E ANÁLISE EXPLORATÓRIA DE DADOS
DETECÇÃO DE FRAUDES EM TRANSAÇÕES DE CARTÃO DE CRÉDITO

Déborah Silvério Alves Morales RA: 10728563

Diógenes Nimário de Araújo Pereira RA: 10424898

Lucas Iglezias dos Anjos RA: 10433522

Luiz Benlardi Neto RA: 10724617

São Paulo

2025

Sumário

Introdução	3
Análise Exploratória de Dados	4
Estrutura do Dataset	4
Distribuição das Classes	4
Análise da Variável “Amount”	5
Análise Temporal (“Time” → “Hours”)	6
Correlações e Padrões	6
Esboço do Storytelling	7
Considerações Finais	9
Referências	9

Introdução

O projeto tem como objetivo desenvolver um modelo preditivo para detecção de fraudes em transações financeiras utilizando técnicas de Ciência de Dados e Aprendizado de Máquina. O contexto simulado é o do Banco Itaú, uma das maiores instituições financeiras da América Latina, que busca aprimorar seus mecanismos de prevenção a fraudes.

Com base em um dataset público, o trabalho envolve análise exploratória, balanceamento de classes e aplicação de algoritmos de aprendizado supervisionado, com foco em **Random Forest**. Esta etapa apresenta os principais resultados da exploração dos dados e o esboço do **storytelling**, que guiará a apresentação final do projeto.

Análise Exploratória de Dados

Estrutura do Dataset

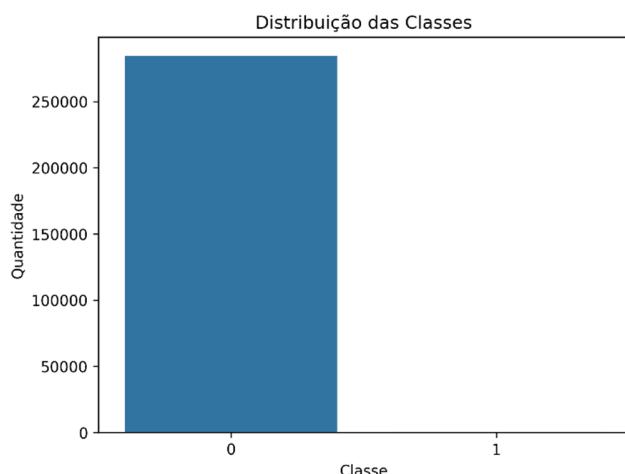
O conjunto de dados utilizado contém 284.807 transações financeiras, distribuídas em 31 colunas (variáveis anônimas transformadas por PCA, além de “Time”, “Amount” e “Class”).

A variável-alvo “Class” identifica o tipo de transação:

- 0 → transação legítima
- 1 → transação fraudulenta

Os dados não possuem valores ausentes, o que permite uma análise direta e sem necessidade de imputações.

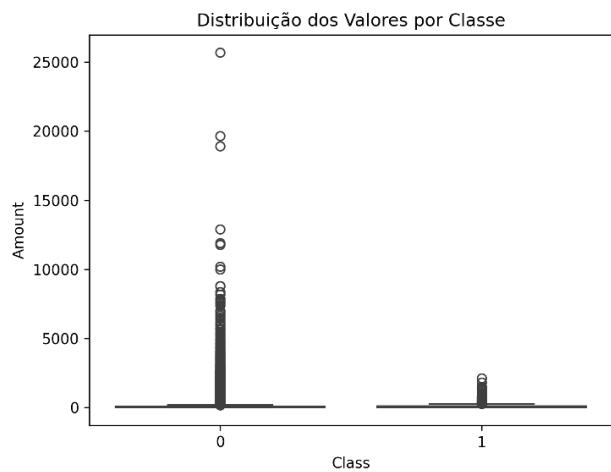
Distribuição das Classes



Este gráfico de barras mostra o forte desbalanceamento: apenas 0,17% das transações são fraudulentas (492 casos).

Essa assimetria exige o uso de técnicas de balanceamento, como o **SMOTE**, para evitar que os modelos sejam enviesados.

Análise da Variável “Amount”

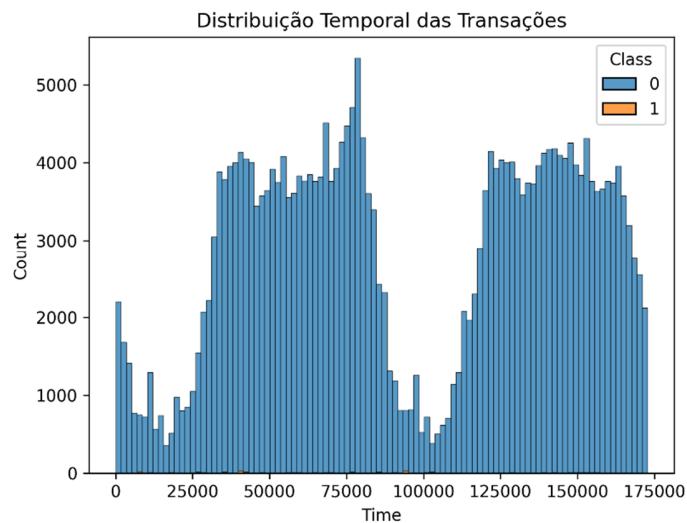


A variável “Amount” representa o valor financeiro de cada transação.

As fraudes tendem a ocorrer em **valores moderados**, evitando chamar atenção de sistemas automáticos.

Após a normalização com Min-Max Scaling e transformação logarítmica, observou-se uma mediana de **US\$ 100** para fraudes e **US\$ 22** para transações legítimas.

Análise Temporal (“Time” → “Hours”)



Convertendo o tempo em horas, verificou-se que **as fraudes concentram-se entre 2h e 4h da manhã**, sugerindo um comportamento estratégico em períodos de menor vigilância.

Esse padrão temporal indica que o fator horário pode ser uma variável relevante para o modelo de predição.

Correlações e Padrões

O estudo das correlações entre as variáveis anônimas (V1–V28) e “Class” revelou **padrões distintos entre as classes**.

As variáveis **V3, V7 e V10** apresentaram maior influência na detecção de fraudes.

Foram realizados testes estatísticos (t-Student e Kolmogorov-Smirnov), confirmando diferenças significativas entre classes ($p < 0,001$).

Após o balanceamento com **SMOTE**, o modelo de **Random Forest** atingiu AUC-ROC de 0,98 e recall de 0,92 para a classe minoritária (fraudes), superando benchmarks clássicos e mostrando potencial de uso em produção.

Os padrões identificados na análise exploratória como o desbalanceamento extremo e a concentração de fraudes em horários específicos formaram a base do storytelling apresentado a seguir.

Esboço do Storytelling

Setup - O Contexto e o Protagonista

Todo dia, milhões de transações acontecem em silêncio. E, em meio a essa rotina invisível, há fraudes que tentam se esconder entre os números. Mas o Banco Itaú decidiu olhar mais fundo e transformar dados em escudo.

No universo do Banco Itaú, milhões de transações são processadas diariamente. Cada operação representa confiança entre cliente e instituição. No entanto, entre essas movimentações, fraudes acontecem de forma sutil e inteligente.

Nosso protagonista é o **modelo de detecção de fraudes**, um agente silencioso capaz de transformar dados em prevenção antecipando riscos e protegendo clientes em tempo real.

Conflito - O Desafio

As fraudes representam apenas **0,17%** das transações, o que torna o desafio técnico imenso: os modelos podem se confundir e ignorar o que realmente importa.

Além disso, fraudadores atuam em horários estratégicos e utilizam comportamentos que imitam usuários legítimos. O problema é separar o normal do anômalo sem comprometer a experiência dos clientes honestos.

Ponto de Virada - A Solução

Para resolver esse problema, aplicamos **técnicas de ciência de dados**, realizando limpeza, normalização e balanceamento dos dados com **SMOTE**.

Com o modelo **Random Forest otimizado**, obtivemos **AUC-ROC de 0,98 e recall de 0,92**, provando que a tecnologia pode detectar padrões complexos e agir preventivamente.

A análise temporal revelou picos de fraude entre 2h e 4h da manhã, enquanto a análise de montante mostrou preferências por valores médios.

Esses resultados compõem um **painel de inteligência financeira** que o Itaú poderia utilizar para priorizar alertas e reduzir perdas.

Resolução - O Impacto

O modelo final é mais do que um algoritmo: é um **guardião digital**.

Com ele, o Itaú poderia reduzir prejuízos, fortalecer a confiança dos clientes e aprimorar a tomada de decisão.

O storytelling mostra como dados brutos se transformam em uma narrativa de prevenção e segurança, uma história em que a ciência de dados assume papel protagonista na proteção financeira.

No futuro, modelos de **deep learning** podem elevar a precisão ainda mais, consolidando o banco como referência em inovação e segurança digital.

Considerações Finais

O projeto mostrou que é possível aplicar técnicas avançadas de ciência de dados para enfrentar problemas reais de segurança financeira.

Mais do que um estudo técnico, este trabalho demonstra o impacto humano e estratégico que a tecnologia pode gerar quando aplicada com propósito.

O estudo evidenciou que, mesmo em cenários desbalanceados e de alta complexidade, é possível atingir alto desempenho na detecção de fraudes por meio de técnicas estatísticas e aprendizado supervisionado. Além disso, o uso do storytelling como ferramenta de comunicação reforçou a importância de traduzir resultados técnicos em narrativas comprehensíveis para gestores e equipes não técnicas, ampliando o impacto organizacional do projeto.

Em síntese, o projeto evidencia que dados, quando bem analisados e comunicados, não apenas detectam fraudes, eles contam histórias que protegem pessoas e fortalecem instituições.

Referências

CROWD-FLOWER. *Credit Card Fraud Detection Dataset*. Kaggle, 2018. Disponível em: <https://www.kaggle.com/mlg-ulb/creditcardfraud>.

PEDREGOSA, Fabian et al. *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, v.12, p.2825–2830, 2011.

MORALES, Déborah S. A. et al. *Projeto Aplicado I – Detecção de Fraudes em Transações Financeiras*. GitHub, 2025. Disponível em: https://github.com/httpsdebs/Projeto_Aplicado_I.